به نام خدا

دانشکده ریاضی و آمار

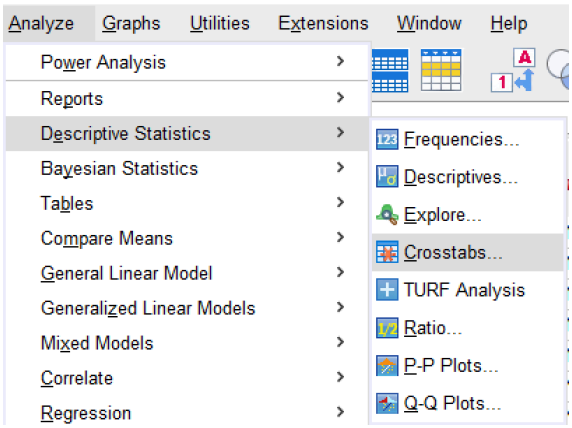
علوم کامپیوتر
نیم‌سال دوم ۰۴-۰۵
داده کاوی

اعضای گروه: زهرا چراغی - محمد ملایی - داوود نصرتی امیرآبادی

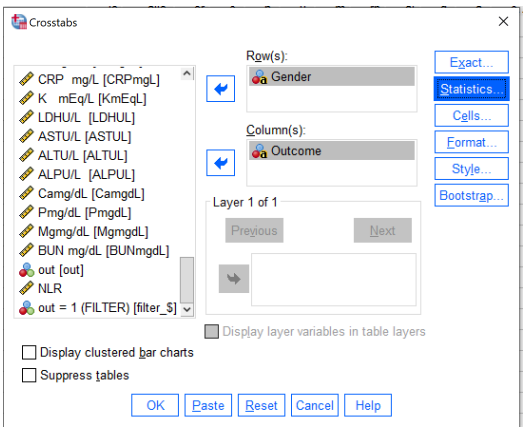
۱ بررسی ارتباط بین متغیر جنسیت و بیمار بودن در داده‌های بیماران کرونایی و غیرکرونایی

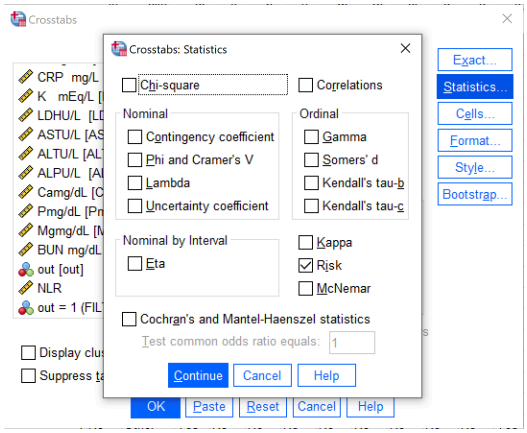
متغیر جنسیت و بیمار بودن هر دو Nominal هستند، بنابراین برای بررسی ارتباط بین این دو متغیر، نمیتوانیم از فرمولهای مربوط به Correlation استفاده کنیم. با توجه به صورت مسئله، داده‌های این بیماران در همان زمان ثبت شده‌اند. پس با یک مطالعه‌ی مقطعی (Cross-sectional) مواجه هستیم و برای بررسی میزان ارتباط و معنادار بودن آن، باید به سراغ محاسبه‌ی OR یا Odds Ratio برویم. قبل از آن، بهتر است تا جدول مربوط به exposure و outcome را رسم کنیم. در اینجا، exposure همان جنسیت و outcome همان بیمار بودن است.

برای اینکار ابتدا وارد نرم‌افزار SPSS شده و از منوی Analyze گزینه Descriptive Statistics و سپس Crosstabs را انتخاب می‌کنیم.



در پنجره باز شده، متغیر Gender را به قسمت Rows و متغیر Outcome را به قسمت Columns منتقل می‌کنیم. سپس روی گزینه Statistics کلیک کرده و در پنجره باز شده، گزینه Risk را انتخاب می‌کنیم. سپس Continue و OK را می‌زنیم.





نتایج به صورت زیر نمایش داده می‌شوند:

Gender * Outcome Crosstabulation

Count

		Outcome		
		COVID-19	non COVID-19	Total
Gender	Female	16	13	29
	Male	14	17	31
Total		30	30	60

Risk Estimate

	Value	95% Confidence Interval	
		Lower	Upper
Odds Ratio for Gender (Female / Male)	1.495	.540	4.136
For cohort Outcome = COVID-19	1.222	.735	2.030
For cohort Outcome = non COVID-19	.817	.488	1.368
N of Valid Cases	60		

نتایج نشان می‌دهد که OR برای Gender (Female / Male) برابر با 1.495 است. بنابراین در این نمونه، شانس ابتلا به COVID-19 در زنان حدود 1.495 برابر شانس ابتلا در مردان است. اما با توجه به اینکه بازه 95% Confidence شامل عدد 1 است، ($1 \in [0.540, 4.136]$) این نتیجه معنادار نیست و نمی‌توانیم بگوییم که جنسیت تأثیری بر بیمار بودن دارد یا خیر.

در ادامه محاسبات صورت گرفته در جدول Risk Estimate را به صورت دستی نیز انجام می‌دهیم:

$$\mathrm{OR} = \frac{(a/b)}{(c/d)} = \frac{a \times d}{b \times c} = \frac{16 \times 17}{13 \times 14} = \frac{136}{91} = 1.4945\ldots \approx 1.495$$

$$\mathrm{SE}\{\ln(\mathrm{OR})\} = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}} = \sqrt{\frac{1}{16} + \frac{1}{13} + \frac{1}{14} + \frac{1}{17}} = \sqrt{\frac{6675}{24752}} \approx 0.519$$

$$\mathrm{CI}_{\mathrm{Interval}} = exp(\ln(\mathrm{OR}) \pm 1.96 \times \mathrm{SE}\{\ln(\mathrm{OR})\}) = exp(\ln(\frac{136}{91}) \pm 1.96 \times \sqrt{\frac{6675}{24752}})$$

$$\mathrm{LB} = exp(\ln(\mathrm{OR}) - 1.96 \times \mathrm{SE}\{\ln(\mathrm{OR})\}) \approx 0.540$$

$$\mathrm{UB} = exp(\ln(\mathrm{OR}) + 1.96 \times \mathrm{SE}\{\ln(\mathrm{OR})\}) \approx 4.136$$

مشاهده می‌شود که نتایج کاملا منطبق با نتایج نرم‌افزار SPSS است. در نتیجه همانطور که اشاره شد به دلیل اینکه

$$1 \in [0.540, 4.136]$$

شواهد کافی برای نتیجه‌گیری درباره وجود ارتباط معنادار بین جنسیت و بیمار بودن وجود ندارد و نمی‌توان جنسیت را در این تحلیل به صورت قطعی risk factor یا protective factor دانست.

۲ محاسبه احتمال مثبت کاذب در سیستم تشخیص دیابت

در این مسئله حساسیت، ویژگی و شیوع بیماری به صورت زیر داده شده‌اند:

$$\text{Sensitivity} = P(T^+ \mid D) = 0.80$$
$$\text{Specificity} = P(T^- \mid \overline{D}) = 0.95$$
$$P(D) = 0.10$$

که در آن D به معنی دیابتی بودن فرد، $\overline{D}$ به معنی دیابتی نبودن فرد و T^+ به معنی مثبت شدن خروجی سیستم است. پس احتمال دیابتی نبودن فرد برابر است با:

$$P(\overline{D}) = 1 - P(D) = 1 - 0.10 = 0.90$$

از طرفی ویژگی سیستم برابر با احتمال منفی شدن تست برای افراد سالم است. بنابراین احتمال مثبت شدن خروجی سیستم برای فردی که واقعا دیابتی نیست، یعنی نرخ مثبت کاذب، برابر است با:

$$P(T^+ \mid \overline{D}) = 1 - \text{Specificity} = 1 - 0.95 = 0.05$$

حال اگر منظور سوال احتمال این رخداد در کل جامعه آماری باشد، باید احتمال همزمان مثبت شدن خروجی سیستم و دیابتی نبودن فرد را محاسبه کنیم:

$$P(T^+ \cap \overline{D}) = P(T^+ \mid \overline{D})P(\overline{D})$$

$$P(T^+ \cap \overline{D}) = 0.05 \times 0.90 = 0.045$$

بنابراین احتمال اینکه در جامعه آماری، خروجی سیستم «داشتن دیابت» باشد ولی فرد واقعا دیابتی نباشد برابر است با:

$$\boxed{0.045 = 4.5\%}$$

برای روشن‌تر شدن تفسیر، اگر سوال را به صورت شرطی در نظر بگیریم، یعنی بخواهیم بدانیم در میان افرادی که خروجی سیستم برای آنها مثبت شده است چه احتمالی وجود دارد که فرد واقعا دیابتی نباشد، باید مقدار $P(\overline{D} \mid T^+)$ را با فرمول بیز محاسبه کنیم:

$$P(\overline{D} \mid T^+) = \frac{P(T^+ \mid \overline{D})P(\overline{D})}{P(T^+ \mid D)P(D) + P(T^+ \mid \overline{D})P(\overline{D})}$$

$$P(\overline{D} \mid T^+) = \frac{0.05 \times 0.90}{0.80 \times 0.10 + 0.05 \times 0.90} = \frac{0.045}{0.125} = 0.36$$

پس احتمال شرطی مثبت کاذب بودن خروجی در میان خروجی‌های مثبت برابر با $\boxed{36\%}$ است. با این حال، با توجه به عبارت «در جامعه آماری»، پاسخ اصلی همان $\boxed{4.5\%}$ است.