به نام خدا

داده‌کاوی پزشکی - پایانترم
نیم‌سال دوم ۰۴-۰۵
جناب آقای دکتر مراتب
داوود نصرتی امیرآبادی

دانشکده ریاضی و آمار

۱. سوال ۱:

پاسخ:

داده‌های مسئله عبارتند از:

$$Se = 0.80, \quad Sp = 0.95, \quad Prev = P(D) = 0.10$$

در اینجا دیابت داشتن را D در نظر می‌گیریم.
چیزی که صورت سوال از ما می‌خواهد «احتمال عدم بیماری به شرط مثبت بودن آزمون» است. این یعنی $P(\bar{D}|T^+)$ که در اینجا مثبت شدن آزمون را با T^+ نشان داده‌ایم.
با توجه به فرمول‌های بیزی احتمالا شرطی داریم:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$
$$\Rightarrow P(\bar{D}|T^+) = \frac{P(T^+|\bar{D})P(\bar{D})}{P(T^+)}$$

خب. در صورت کسر چه داریم؟ $P(T^+|\bar{D})$. این یعنی: احتمال اینکه طرف دیابت نداشته باشد ولی تست ما بگوید او دیابت دارد. این همان نرخ مثبت کاذب یا FPR یا $FalsePositiveRate$ است که از طریق زیر به دست می‌آیدک:

$$FPR = \frac{FP}{FP + TN} = 1 - Sp = 1 - 0.95 = 0.05$$

از طرفی عامل دیگر صورت کسر یعنی $P(\bar{D})$ هم برابر است با $1 - P(D) = 1 - 0.10 = 0.90$
در مخرج نیز شاهد $P(T^+)$ هستیم. یعنی احتمال اینکه تست یکی از کودکان مثبت شود. دو حال داریم. یا اینکه این کودک واقعا دیابت دارد و تست او مثبت شده است. یا اینکه دیابت ندارد و تست او مثبت شده است.
یعنی: $P(D \cap T^+)$ و $P(\bar{D} \cap T^+)$. پس در ادامه خواهیم داشت:

$$P(D \cap T^+) = P(D) \times P(T^+|D) = Prev \times Se = 0.10 \times 0.80 = 0.080$$
$$P(\bar{D} \cap T^+) = P(\bar{D}) \times P(T^+|\bar{D}) = (1 - Prev) \times FPR = 0.90 \times 0.05 = 0.045$$

از طرفی چون این دوحالت هیچ اشتراکی با هم ندارند می‌توانیم آن‌ها را به راحتی با هم جمع کنیم تا مقدار مورد نظر در مخرج را به دست آوریم. پس خواهیم داشت:

$$P(\bar{D}|T^+) = \frac{P(T^+|\bar{D})P(\bar{D})}{P(T^+)} = \frac{0.05 \times 0.90}{0.080 + 0.045} = \frac{0.045}{0.125} = 0.36$$

پس احتمال شرطی عدم بیماری به شرط مثبت بودن آزمون برابر با 36% است. این یعنی از میان کودکانی که نتیجه تست و آزمون دیابت آن‌ها مثبت از آب در می‌آید، 36 درصد واقعا دیابت ندارند و صرفا نتیجه آزمونشان مثبت کاذب بوده است.
البته بعد از محاسبه پاسخ به این روش متوجه شدم که با استفاده از فرمول FDR می‌توان به پاسخ مورد نظر رسید چرا که تعریف FDR همان مقدار مورد نظر سوال است.
داریم:

$$\begin{aligned} FDR &= \frac{FP}{FP + TP} = 1 - PPV \\ PPV &= \frac{Se \times Prev}{(Se \times Prev) + ((1 - Sp) \times (1 - Prev))} \\ &= \frac{0.80 \times 0.10}{(0.80 \times 0.10) + (0.05 \times 0.90)} = 0.64 \\ \Rightarrow FDR &= 1 - 0.64 = 0.36 \end{aligned}$$

۲. سوال ۲:

پاسخ:

گرچه در صورت سوال ذکر نشده اما باید دقت داشته باشیم که برای استفاده از روشی توکی، لازم است که میزان Skewness داده ها مشخص شود که اگر زیاد باشد، توکی به درستی عمل نخواهد کرد. طبق گفته های استاد در کلاس این به دلیل آن است که ضریب ۵.۱ که در ادامه به آن اشاره میکنیم با فرض نرمال توزیع داده ها در نظر گرفته شده است و در صورت نرمال نبودن توضیح دیگر نمیتوان از این ضریب استفاده کرد.

$$\text{Skewness Pearson} = \frac{3 \times (mean - median)}{standard\ deviation}$$

این مقدار را برای داده های موجود در صورت سوال انجام دادیم:

```python
import pandas as pd
import numpy as np

data = pd.read_csv("outlier_data.csv")
data_v3 = data["variable_3"]

mean_v3 = data_v3.mean()
median_v3 = data_v3.median()
std_v3 = data_v3.std(ddof=1)    "ddof": Unknown word.
pearson_skewness = 3 * (mean_v3 - median_v3) / std_v3
print(f"Pearson skewness = {pearson_skewness:.3f}")
```

```
Pearson skewness = -0.298
```

تحلیل جواب به این صورت است که توزیع مورد بحث ما چولگی خاصی به سمت راست و چپ ندارد و داده به طور متوازن پخش شده است. درواقع اگر این عدد کمتر از -1 میبود میگفتیم که چولگی به سمت چپ است و اگر بیشتر از 1 میبود میگفتیم چولگی به سمت راست است.

حالا به سراغ کار با روش توکی می‌رویم. ابتدا چارک اول و سوم را به دست آورده و از هم کم می‌کنیم تا مثدار IQR به دست آید. سپس چارک اول را منهای 1.5 برابر مقدار IQR کرده و کران پایین مینامیم. همچنین، چارک سوم را به علاوه‌ی 1.5 برابر مقدار IQR کرده و کران بالا می‌نامیم. این ضریب 1.5 همان ضریبی است که گفتیم بر مبنای نرمال بودن داده‌ها از آن استفاده می‌کنیم. در نهایت داده‌های خارج از این کران را داده‌ی پرت در نظر می‌گیریم.

```python
Q1 = np.percentile(data_v3, 25, method="weibull")    "weibull": Unknown word.
Q3 = np.percentile(data_v3, 75, method="weibull")    "weibull": Unknown word.
IQR = Q3 - Q1

tukey_low = round(Q1 - 1.5 * IQR, 3)    "tukey": Unknown word.
tukey_up = round(Q3 + 1.5 * IQR, 3)    "tukey": Unknown word.

outliers_mask = (data_v3 < tukey_low) | (data_v3 > tukey_up)    "tukey": Unknown
outliers = data[outliers_mask][["sample_id", "variable_3"]].round(3)

print(f"Q1 = {Q1:.3f}")
print(f"Q3 = {Q3:.3f}")
print(f"IQR = {IQR:.3f}")
print(f"Tukey lower and upper bounds are = [{tukey_low:.3f}, {tukey_up:.3f}]")
outliers
```

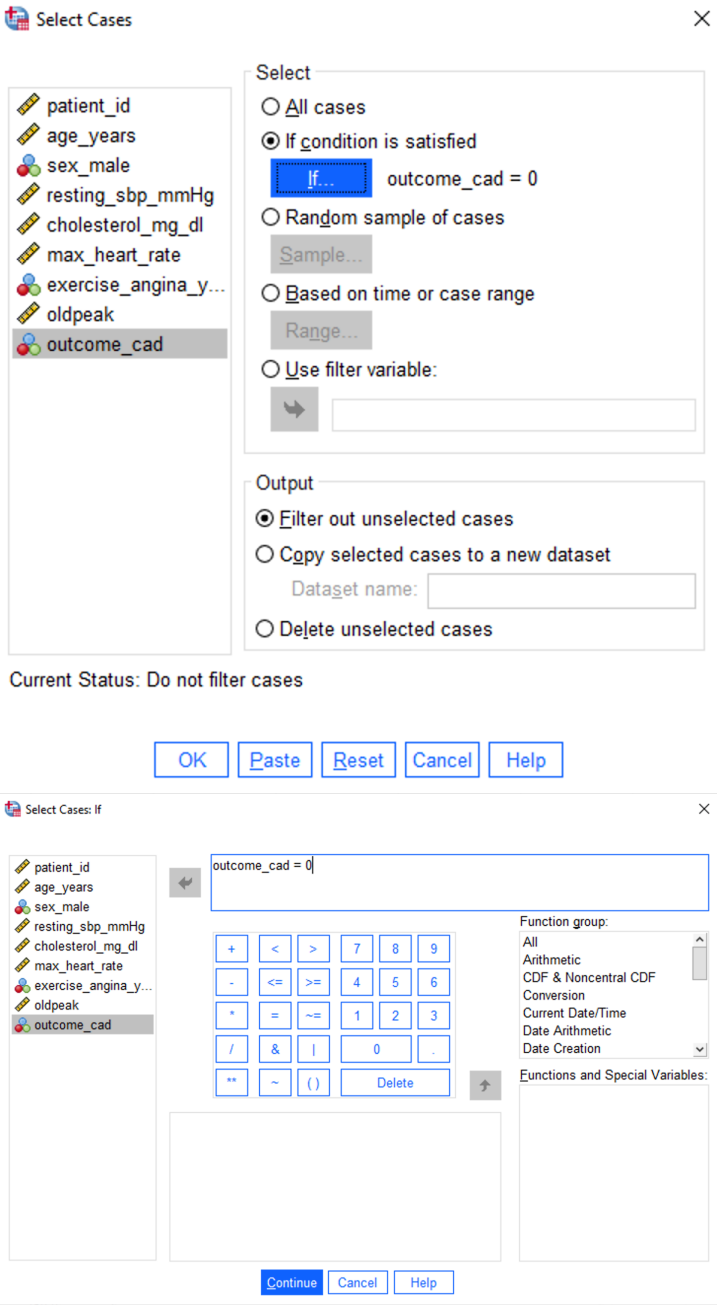
```
Q1 = 0.722
Q3 = 1.050
IQR = 0.328
Tukey lower and upper bounds:
[0.229, 1.542]
```

همانطور که مشخص است سمپلهای $14, 39, 66, 101$ داده پرت محسوب شده‌اند.
در مورد بخش انتهایی سوال هم باید این نکته را را مد نظر داشته باشیم که احتمالهای مختلفی اعم از اشتباه ایجنت انسانی وارد کننده اطلاعات، تبدیلات عددی غیرمنتظره در ماشین، نمایش نامناسب اعداد و ... ممکن است باعث ایجاد خطا شده و داده را به اشتباه پرت محسوب کنند. پس نباید داده‌ها را طی یک روند اتوماتیک پس از تشخیص پرت بودن حذف کنیم.

۳. سوال ۳:

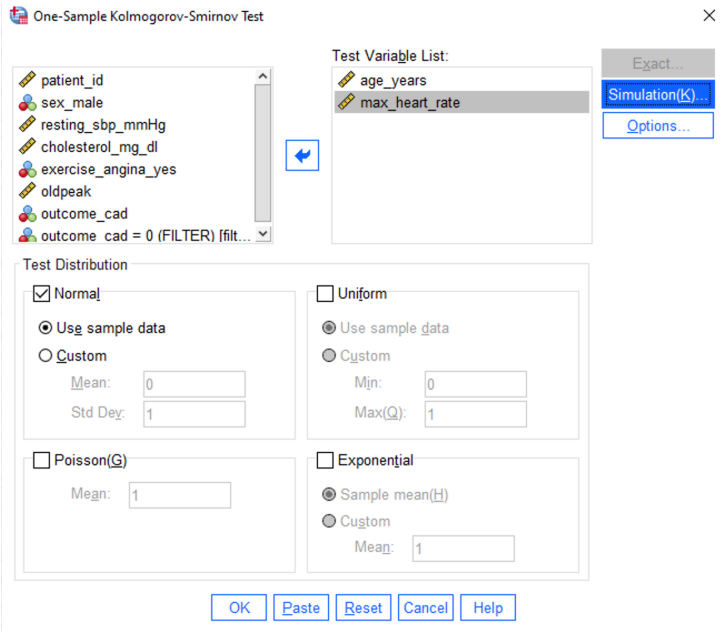
پاسخ:

ابتدا از منوی File -> Import data -> CSV data اقدام به وارد کردن داده‌ها میکنیم. سپس طبق تصویر به منوی Data -> Select Cases وارد شده و گزینه If condition is satisfied را انتخاب میکنیم. بعد مطابق خواسته ی سوال، شرط $outcome_cad = 0$ را نوشته و تایید میکنیم.



به منظور بررسی همبستگی بین متغیرها ابتدا باید نوع آنها را مشخص کنیم. وقتی به ستونهای متناظر آنها

نگاه کرده و مقادیر را بررسی می‌کنیم متوجه میشویم که هر دو از نوع Interval هستند. بعد از این، باید نرمال بودن آنها را مورد بررسی قرار دهیم. در این جا باید به این نکته دقت کنیم که تعداد داده‌های ما چند تاست. با توجه به شرطی که در ابتدا لحاظ کردیم ۱۵۷ داده برای ما باقی مانده است که به ما اجازه استفاده از تست کولموگروف-اسمیرنوف را می‌دهد.
از منوی Analyze -> Nonparametric Tests -> Legacy Dialogs -> 1 Sample K-S وارد شده و متغیرهای مورد نظر را انتخاب میکنیم. سپس در قسمت Test Distribution گزینه Normal را انتخاب کرده و روی گزینه OK کلیک میکنیم:



نتایج این تست به صورت زیر است:

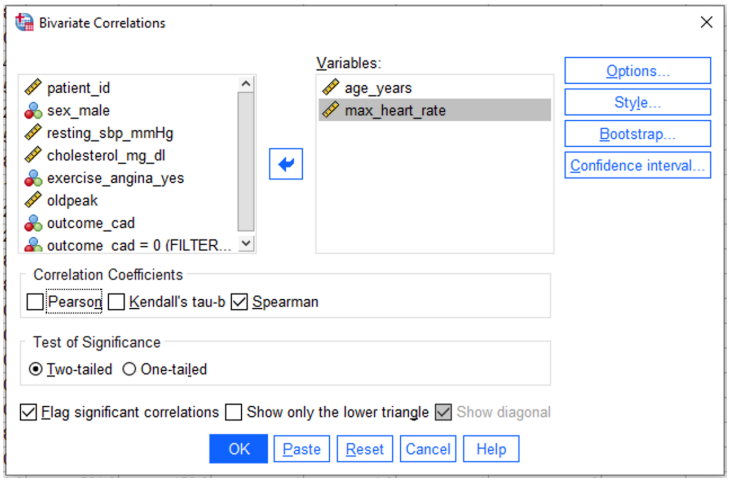
One-Sample Kolmogorov-Smirnov Test

			age_years	max_heart_rate
N			157	157
Normal Parameters[a,b]	Mean		52.77	157.981
	Std. Deviation		9.483	19.3886
Most Extreme Differences	Absolute		.074	.079
	Positive		.074	.046
	Negative		-.054	-.079
Test Statistic			.074	.079
Asymp. Sig. (2-tailed)[c]			.035	.018
Monte Carlo Sig. (2-tailed)[d]	Sig.		.034	.016
	99% Confidence Interval	Lower Bound	.029	.013
		Upper Bound	.038	.020

a. Test distribution is Normal.
b. Calculated from data.
c. Lilliefors Significance Correction.
d. Lilliefors' method based on 10000 Monte Carlo samples with starting seed 2000000.

همانطورکه می‌بینم مقدار $p-value$ برای هر دو متغیر age_years و max_heart_rate برابر با 0.035 و 0.016 است که هر دو کمتر از 0.05 هستند و این یعنی از توزیع نرمال پیروی نمی‌کنند.

در نتیجه با توجه به نتایج باید تست $Spearman$ بگیریم. برای این کار از منوی Analyze -> Correlate -> Bivariate وارد شده و متغیرهای مورد نظر را انتخاب میکنیم. سپس تیک گزینه Spearman را زده و سپس تیک گزینه Pearson را برمیداریم و روی گزینه OK کلیک میکنیم:



نتایج به صورت زیر هستند:

Correlations

			age_years	max_heart_rate
Spearman's rho	age_years	Correlation Coefficient	1.000	-.500**
		Sig. (2-tailed)	.	<.001
		N	157	157
	max_heart_rate	Correlation Coefficient	-.500**	1.000
		Sig. (2-tailed)	<.001	.
		N	157	157

**. Correlation is significant at the 0.01 level (2-tailed).

حالا آن را تحلیل می‌کنیم. مقدار $p-value$ کمتر از 0.05 است پس معنادار است. اما برای بررسی شدت آن باید به سراغ Correlation Coefficient برویم که مقدار -0.5 را دارد. با توجه به اینکه $|-0.5| = 0.5 > 0.3$ پس این همبستگی از شدت هم برخوردار است. در واقع ما با یک همبستگی معنادار با شدت متوسط روبه رو هستیم که در جهت عکس (مخالف) است. بدین معنی که با افزایش سن افراد، حداکثر ضربان قلب آنها کاهش می‌یابد.

با این حال باید توجه داشته باشیم که این correlation رابطه علی و causation را توجیه نمیکند و صرفا رابطه این دو متغیر را نشان میدهد. چرا که ممکن است عوامل دیگری نیز در این رابطه نقش داشته باشند.

۴. سوال ۴:

پاسخ:

ابتدا مقادیر داده شده در صورت سوال را به فرم متعارف مینویسیم:

	Postive Outcome	Negative Outcome
Exposed Group	a	b
Unexposed Group	c	d

با توجه به داده‌های صورت سوال داریم:

	Diseased	Non-diseased
Angina Present	69	23
Angina Not Present	56	134

برای محاسبه OR یا همان Odds Ratio از فرمول زیر استفاده میکنیم::

$$OR = \frac{ad}{bc} = \frac{69 \times 134}{23 \times 56} = 7.179$$

همچنین برای محاسبه CI 95% داریم:

$$CI_{95\%} = \exp[\ln(OR) \pm 1.96 \times SE\{\ln(OR)\}]$$

که مقدار SE خود از فرمول زیر به دست می‌اید:

$$SE\{\ln(OR)\} = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

پس داریم:

$$SE\{\ln(OR)\} = \sqrt{\frac{1}{69} + \frac{1}{23} + \frac{1}{56} + \frac{1}{134}} = 0.289$$

و خواهیم داشت:

$$CI_{95\%} = \exp[\ln(7.179) \pm 1.96 \times 0.289] = [4.074, 12.649]$$

مقدار RR نیز برابر است با:

$$RR = \frac{a/(a+b)}{c/(c+d)} = \frac{69/(69+23)}{56/(56+134)} = 2.545$$

حالا به تفسیر جواب‌ها میپردازیم: مقدار OR برابر با 7.179 است. این یعنی شانس وجود بیماری عروق کرونر در افراد دارای آنژین ناشی از فعالیت، 7.179 برابر افراد بدون آنژین است. چون فاصله اطمینان شامل عدد 1 نیست، این ارتباط از نظر آماری معنادار است.
با توجه به متن سوال، ما با یک مطالعه Cohort طرف نیستیم و مطالعه با توجه به ثبت همزمان یک مطالعه Cross Sectional محسوب میشود. این باعث میشود که ما RR را با احتیاط بیان کنیم. یعنی نمیتوانیم با اطمینان بگوییم که چون RR ما 2.545 است، پس افراد دارای آنژین، 2.545 برابر افراد بدون آنژین در معرض خطر ابتلا به بیماری عروق کرونر هستند (ریسک ابتلا در آینده).

۵. سوال ۵:

پاسخ:

خب. چون در صورت سوال به این موضوع اشاره شده که عرض از مبدأ در نظر گرفته شود، در مرحله نخست باید در کنار متغیرهای اولیه دیتاست، یک ستون شامل 1 به مجموعه‌ی دیتا اضافه کنیم (همان Intercept). برای اینکار از قطعه کد زیر بهره میجوییم:

```
import pandas as pd
import numpy as np

data = pd.read_csv('outlier_data.csv')
data_var = data[["variable_1", "variable_2", "variable_3"]]

correlation_matrix = data_var.corr()

data_X = np.column_stack([
    np.ones(data_var.shape[0]),
    data_var.to_numpy(),
])
cond_raw = np.linalg.cond(data_X)    "linalg": Unknown word.
```

البته در وهله اول ماتریس همبستگی را هم در متغیری ذخیره کردیم تا بعدا آن را نمایش دهیم.
در مرحله ی بعدی هم باید استانداردسازی را با توجه به فرمول زیر انجام دهیم:

$$z = \frac{x - mean}{sd} = \frac{x - \mu}{\sigma}$$

```
z = (data_var - data_var.mean()) / data_var.std(ddof=1)    "ddof":
data_X_z = np.column_stack([
    np.ones(z.shape[0]),
    z,
])
cond_z = np.linalg.cond(data_X_z)    "linalg": Unknown word.

print(f"Correlation matrix:\n{correlation_matrix}")
print(f"Condition number of the raw data: {cond_raw:.4f}")
print(f"Condition number of the standardized data: {cond_z:.4f}")
```

حالا نتایج را در زیر آورده و به بررسی آنها میپردازیم:

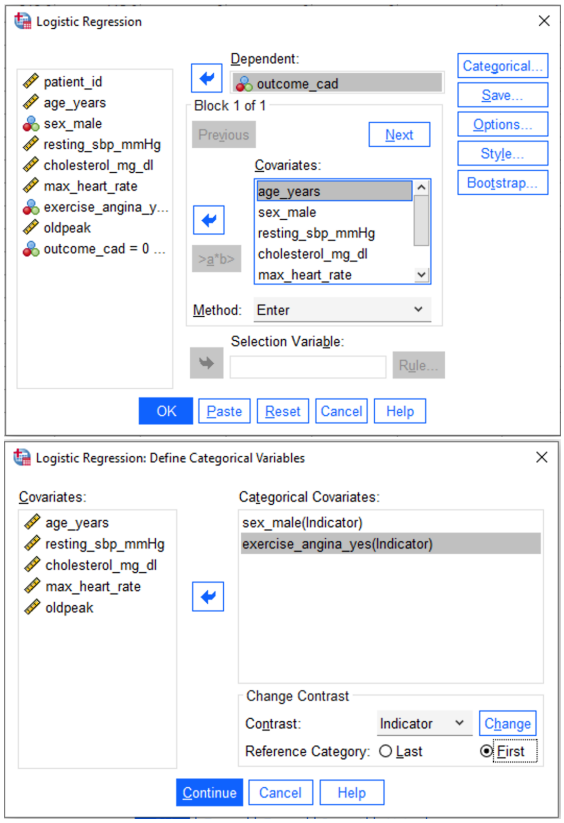
```
Correlation matrix:
            variable_1  variable_2  variable_3
variable_1    1.000000    0.007498   -0.073107
variable_2    0.007498    1.000000   -0.004640
variable_3   -0.073107   -0.004640    1.000000
Condition number of the raw data: 1653.6506
Condition number of the standardized data: 1.0765
```

خب. همانطور که در تصویر مشخص است کاندیشن نامبر دیتای اولیه برابر با 1653.650 بود. اما پس از استانداردسازی به طرز قابل توجهی به 1.077 کاهش پیدا کرد. از طرفی، وقتی به ماتریس همبستگی آنها نگاه میکنیم به اعداد $0.007, -0.073, 0.005$ برخورد می‌کنیم که تقریبا برابر با صفر هستند. یعنی همبستگی خاصی بین ستون‌ها (ویژگی‌ها) وجود نداشته است. همه‌ی اینها باعث میشوند تا نتیجه بگیریم که بالا بودن عدد شرطی قبل از استانداردسازی نه بخاطر همخطی شدید، بلکه به خاطر تفاوت مقایسها رخ داده است.

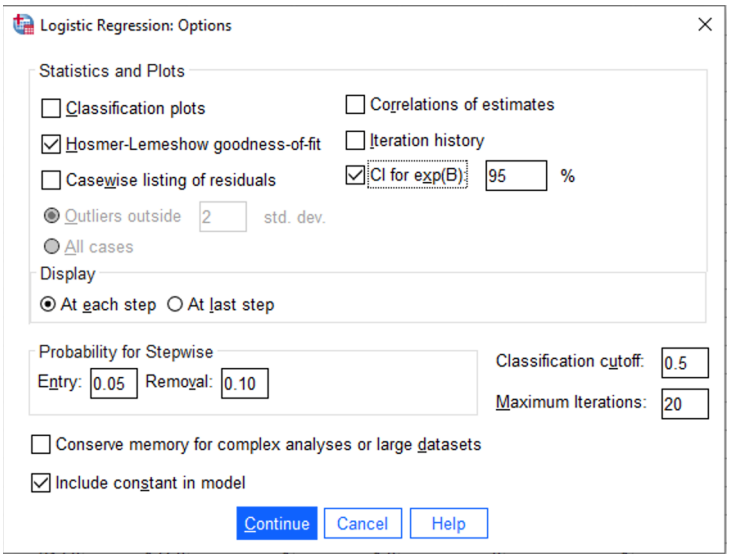
۶. سوال ۶:

پاسخ:

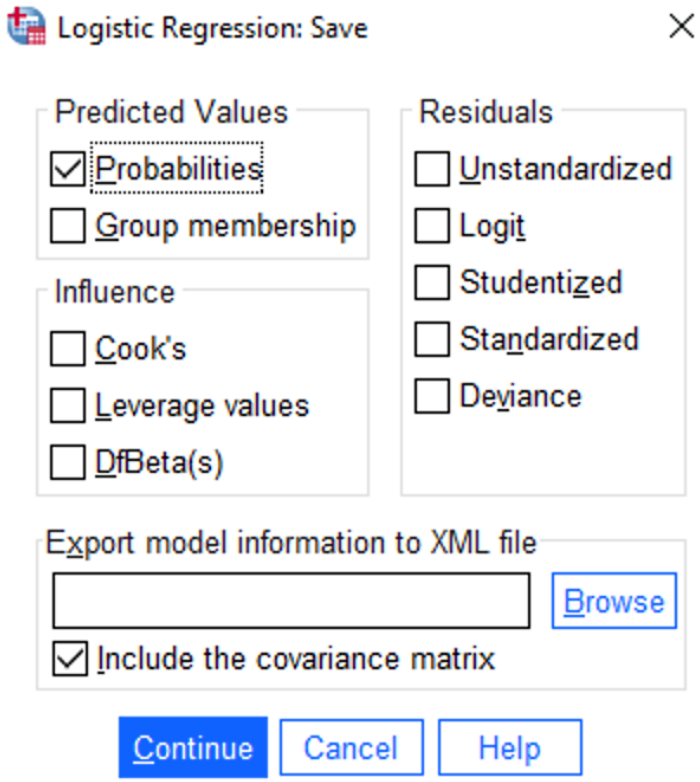
چون outcome_cad یک متغیر باینری است، از منوی Analyze -> Regression -> Binary Logistic وارد شده و طبق تصویر متغیرهای خواسته شده را در قسمت Covariates قرار میدهیم. سپس در قسمت Categorical متغیر outcome_cad را قرار داده و روی گزینه Categorical میزنیم و چون متغیرهای sex_male و exercise_angina_yes کتگوریکال یا همان کیفی بودند، آن ها را طبق تصویر مشخص و اضافه میکنیم و در نهایت گزینه First را زده و روی Continue کلیک می‌کنیم:



سپس در قسمت Options وارد شده و تیک گزینه‌های Hosmer-Lemeshow goodness-of-fit و CI 95% را زده و روی گزینه تایید کلیک می‌کنیم. در واقع این موارد در صورت سوال ذکر شده بودند و نیازشان خواهیم داشت. نکته اینجاست که تیک گزینه Include constant را برنمیداریم تا بعد از دیدن p-value آن تصمیم بگیریم که معنادار است یا خیر:



در نهایت هم در قسمت Save وارد شده و تیک گزینه Probabilities را میزنیم تا در نتایج مورد نظر ما احتمالات هم وجود داشته باشد:



حالا با خیال راحت روی گزینه OK میزنیم. نتیجه به صورت زیر است:

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I.for EXP(B) Lower	Upper
Step 1[a]	age_years	.015	.020	.529	1	.467	1.015	.975	1.056
	sex_male(1)	-1.900	.394	23.205	1	<.001	.150	.069	.324
	resting_sbp_mmHg	.013	.009	1.952	1	.162	1.013	.995	1.032
	cholesterol_mg_dl	.008	.003	6.821	1	.009	1.008	1.002	1.015
	max_heart_rate	-.029	.009	11.257	1	<.001	.971	.955	.988
	exercise_angina_yes(1)	-1.285	.347	13.755	1	<.001	.277	.140	.545
	oldpeak	.609	.154	15.668	1	<.001	1.838	1.360	2.485
	Constant	.279	2.036	.019	1	.891	1.322		

a. Variable(s) entered on step 1: age_years, sex_male, resting_sbp_mmHg, cholesterol_mg_dl, max_heart_rate, exercise_angina_yes, oldpeak.

همانطور که میبینیم مقدار p-value برای Constant یا همان β_0 ما به طرز واضحی از 0.05 بیشتر است (۰۵.۰ < ۸۹۱.۰) که نوید از معنادار نبود این ضریب میدهد. به ناچار مدل را دوباره اجرا می‌کنیم ولی این بار دیگر آن تیک مذکور را نمیزنیم:

Classification Table[a]

	Observed		Predicted outcome_cad 0	1	Percentage Correct
Step 1	outcome_cad	0	133	24	84.7
		1	36	89	71.2
	Overall Percentage				78.7

a. The cut value is .500

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I.for EXP(B) Lower	Upper
Step 1[a]	age_years	.016	.017	.918	1	.338	1.016	.983	1.051
	sex_male(1)	-1.907	.392	23.699	1	<.001	.148	.069	.320
	resting_sbp_mmHg	.014	.009	2.395	1	.122	1.014	.996	1.031
	cholesterol_mg_dl	.008	.003	7.150	1	.007	1.009	1.002	1.015
	max_heart_rate	-.028	.007	18.046	1	<.001	.972	.959	.985
	exercise_angina_yes(1)	-1.287	.346	13.813	1	<.001	.276	.140	.544
	oldpeak	.611	.153	15.951	1	<.001	1.842	1.365	2.487

a. Variable(s) entered on step 1: age_years, sex_male, resting_sbp_mmHg, cholesterol_mg_dl, max_heart_rate, exercise_angina_yes, oldpeak.

Activate W

با توجه به سطر exercise_angina_yes(1) مقدار ضریب آن (ضریب بتا) برابر با -1.287 است. چون این ضریب منفی است، نتیجه میگیریم که این فیچر یک یک protective factor است. یعنی با افزایش این متغیر، احتمال ابتلا به بیماری عروق کرونر کاهش می‌یابد. از طرفی میدانیم که مقدار $OR = e^{\beta}$ است پس از روی ستون $Exp(B)$ مقدار آن برابر با 0.276 خواهد بود. در نتیجه با توجه به اینکه این مقدار کمتر از یک شده است میتوان نتیجه گرفت که متبلا نبودن به CAD ارتباط بیشتری با آنژین فعالیت داشتن دارد (یعنی آنژین داشتنش ارتباط بیشتری با CAD نداشتنش دارد). در مورد p-value هم باید گفت که زیر 0.05 است پس معنادار است و نشان میدهد که این یک فیچر مهم است. در ادامه هم با توجه به جدول، $CI_{95\%}$ را داریم که عبارت است از:

$$CI_{95\%} = [0.140, 0.544]$$

۷. سوال ۷:

پاسخ:

خب. مشخصا در صورت سوال ذکر شده که آستانه را باید روی 0.5 تنظیم کرد. پس با توجه به کد پایتون زیر اقدام به بررسی فولدهای مختلف میکنیم. دقت کنیم که با استفاده از تابع confusion_matrix استفاده کردیم که به صورت aggregated اقدام به محاسبه چهارمقدار tn، fp، fn، tp خواهد کرد و سپس نتیجه را به صورت کلی اعلام می‌کند:

```python
import pandas as pd
from sklearn.metrics import confusion_matrix

d = pd.read_csv("CV_predictions.csv")
y = d["observed_outcome"]
p = (d["predicted_probability"] >= 0.5).astype(int)

tn, fp, fn, tp = confusion_matrix(y, p).ravel()

print(f"Confusion matrix:\ntn: {tn}\nfp: {fp}\nfn: {fn}\ntp: {tp}")
print("Sensitivity:", tp / (tp + fn))
print("Specificity:", tn / (tn + fp))
print("PPV:", tp / (tp + fp))
print("NPV:", tn / (tn + fn))
print("Accuracy:", (tp + tn) / len(d))
```

✓ 0.0s Python

```
Confusion matrix:
tn: 130
fp: 27
fn: 38
tp: 87
Sensitivity: 0.696
Specificity: 0.8280254777070064
PPV: 0.7631578947368421
NPV: 0.7738095238095238
Accuracy: 0.7695035460992907
```

طبق تصویر داریم:

$$
\begin{aligned}
Se &= 69.6\% \\
Sp &= 82.803\% \\
PPV &= 76.316\% \\
NPV &= 77.381\% \\
Acc &= 76.950\%
\end{aligned}
$$

و این یعنی اینکه:

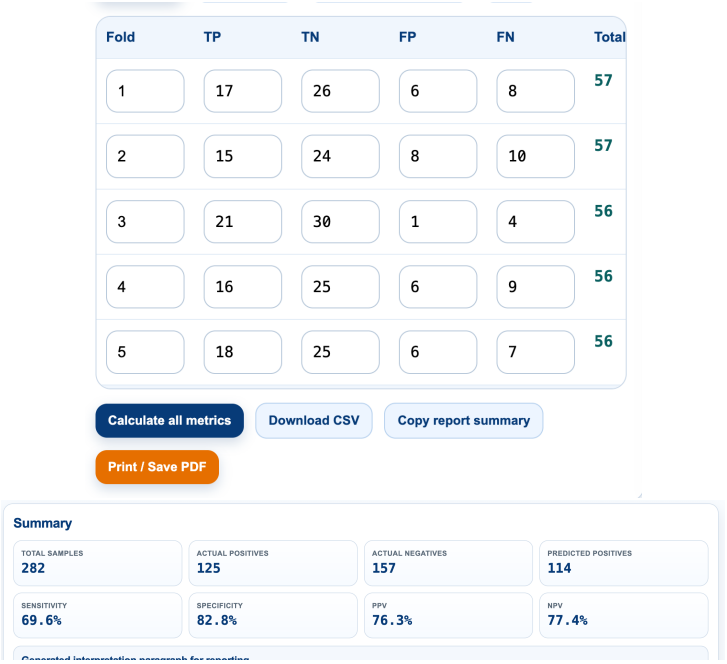
- مقدار Se به ما نشان میدهد که مدل تقریبا در ۷۰ درصد مواقع، موارد مثبت را به درستی تشخیص می‌دهد.
- از طرفی Sp هم نشان میدهد که مدل تقریبا در ۸۳ درصد مواقع، موارد منفی را به طور صحیح تشخیص می‌دهد.
- مقدار PPV به این معنی است که تقریبا در ۷۶ درصد مواقع، مواردی که مثبت تشخیص داده شده بودند واقعا هم مثبت بودند.
- سپس NPV میگوید که تقریبا در ۷۷ درصد مواقع مواردی که منفی تشخیص داده شده‌اند، واقعا منفی بوده‌اند.
- در نهایت Acc ۷۷ درصدی نیز بدین معنی است که تقربیا در ۷۷ درصد مواقع یک طبقه‌بندی درست به ما می‌دهد.

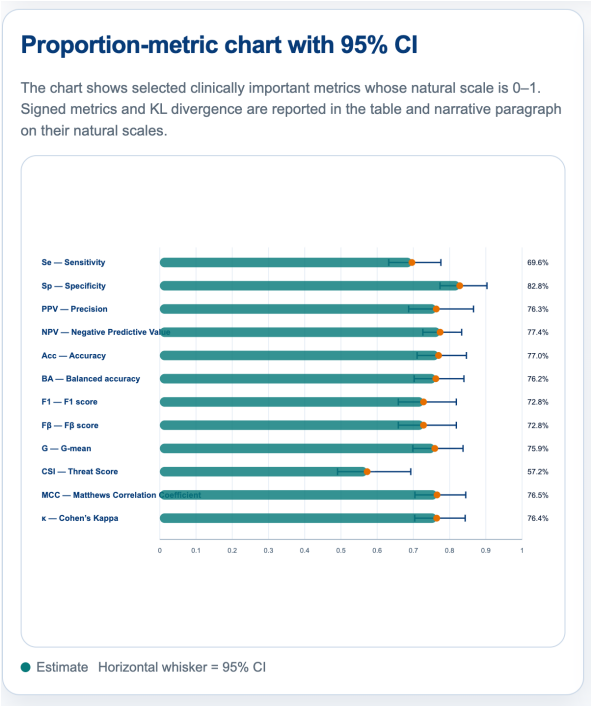
تفسیر ما میتواند این باشد که مدل در شناسایی افراد واقعاً منفی، با ویژگی 82.8% ،بهتر از یافتن همهٔ موارد ابتلا با حساسیت 69.6% عمل می‌کند.
البته ما این کار را بدون aggregation همی میشد انجام دهیم. یعنی به ازای هر فولد مقادیر را محاسبه کنیم و پاسخ را به اپ مورد اشاره در صورت سوال بدهیم. در این صورت با کد زیر به نتیجه زیر میرسیدیم:



	Fold	TN	FP	FN	TP
0	1	26	6	8	17
1	2	24	8	10	15
2	3	30	1	4	21
3	4	25	6	9	16
4	5	25	6	7	18

سپس با دادن مقادیر به اپ، نتیجه زیر را میداشتیم:





که مشاهده می‌شود نتایج آن مطابق با نتایج متد قبلی است.

۸. سوال ۸:

پاسخ:

الف:

همان کد قبلی را اجرا می‌کنیم ولی به جای 0.5 از 0.3 استفاده می‌کنیم. نتیجه به صورت زیر خواهد بود:

```python
import pandas as pd
from sklearn.metrics import confusion_matrix

d = pd.read_csv("CV_predictions.csv")
rows = []

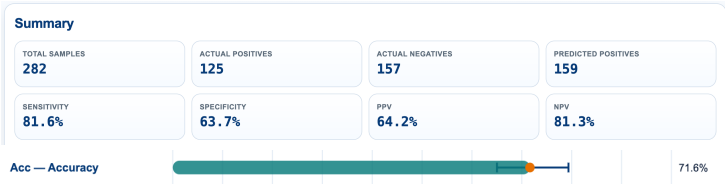
for fold, g in d.groupby("fold"):
    y = g["observed_outcome"]
    p = (g["predicted_probability"] >= 0.3).astype(int)
    tn, fp, fn, tp = confusion_matrix(y, p, labels=[0, 1]).ravel()

    rows.append({
        "Fold": fold,
        "TN": tn,
        "FP": fp,
        "FN": fn,
        "TP": tp,
    })

results = pd.DataFrame(rows)
results
```

0.0s

	Fold	TN	FP	FN	TP
0	1	19	13	6	19
1	2	17	15	6	19
2	3	23	8	1	24
3	4	20	11	8	17
4	5	21	10	2	23



که عبارتند از:

$$Se = 81.6\%$$
$$Sp = 63.7\%$$
$$PPV = 64.2\%$$
$$NPV = 81.3\%$$
$$Acc = 71.6\%$$

همانطور که مشخص است وقتی این موارد را با موارد سوال قبلی که با 0.5 به دست آورده شده بودند مقایسه میکنیم، متوجه افزایش Se میشویم. این بدان معنی است مدل در مشخص کردن موارد مثبت بهتر عمل می‌کند. اما این تغییر آستانه با کاهش ویژگی یا همان Sp هم همراه بوده. پس برای پاسخ به قسمت الف باید گفت آن وقتهایی که برای ما تشخیص مثبت بودن بیماری اهمیت بیشتری دارد این آستانه بهتر است. در غیر این صورت همان آستانه قبلی مناسب‌تر است.

ب: با توجه به صورت سوال تابع هزین هرا به صورت زیر مینویسیم:

$$Cost(t) = 4FN_t + FP_t$$

با توجه به جداولی که در این سوال و سوال قبل داشتیم، برای آستانه 0.5 داشتیم $FN = 38$ و $FP = 27$ پس تابع میشود:

$$Cost(0.5) = 4(38) + 27 = 152 + 27 = 179$$

همینطور برای 0.3 داشتیم $FN = 23$ و $FP = 57$ پس تابع میشود:

$$Cost(0.3) = 4(23) + 57 = 92 + 57 = 149$$

چون هزینه در آستانه 0.3 کمتر شد، آن را برای غربالگری انتخاب میکنیم. با توجه به فرمول، در این تابع هزینه برای ما FN اهمیت بالاتری داشت، یعنی نمیخواستیم کسی که بیمار است را به اشتباه سالم تشخیص دهیم.
و خب برای بررسی اثر شیوع هم باید این نکته را در نظر داشته باشیم که بر اساس فرمول

$$PPV = \frac{Se \times Prev}{(Se \times Prev) + ((1 - Sp) \times (1 - Prev))}$$

شیوع با PPV ارتباط کاملا مستقیمی دارد و با افزایش آن، ما شاهد این خواهیم بود که احتمال اینکه نمونه‌های مثبتی که اعلام کردیم واقعا مثبت باشند افزایش پیدا میکند.

۹. سوال ۹:

پاسخ:

خب. در این روش دو نوع نشت داده داریم. اول اینکه پژوهشگر محترم قبل از شروع اعتبارسنجی متقاطع، کل دیتا را استاندارد کرده اند. یعنی میانگین و انحراف معیار با استفاده از همهٔ نمونه ها، حتی نمونه‌هایی که بعدا در fold آزمون قرار می‌گیرند، حساب شده است. پس مدل موقع آموزش به شکل غیرمستقیم از دیتای آزمون هم اطلاعات گرفته است.
مشکل دومی هم است. بهترین feature ها را با استفاده از outcome_cad روی کل دیتا انتخاب کرده‌اند. در این حالت برچسب نمونه‌های آزمون هم در انتخاب feature ها دخالت دارد؛ پس دیگر fold آزمون واقعا دیده‌نشده و مستقل نیست.
برای حل این مشکل باید از Nested Cross-Validation استفاده کنیم. مثلا ابتدا دیتا را به پنج fold بیرونی تقسیم می‌کنیم. در هر مرحله یک fold را فقط برای تست نهایی کنار می‌گذاریم و چهار fold دیگر دیتای آموزش ما هستند. این fold آزمون بیرونی نباید در استانداردسازی، انتخاب feature، انتخاب مدل یا تنظیم hyperparameterها استفاده شود.
حالا فقط روی همان چهار fold آموزشی، یک CV داخلی اجرا می‌کنیم. در هر تقسیم داخلی، میانگین و انحراف معیار را فقط از بخش train داخلی به دست می‌آوریم و با همان مقادیر بخش validation را استاندارد می‌کنیم. انتخاب feature هم باید فقط با استفاده از outcome_cad بخش train داخلی انجام شود. بعد مدل‌ها و تنظیمات مختلف را روی validation داخلی مقایسه کرده و بهترین pipeline را انتخاب می‌کنیم.
در نهایت بهترین pipeline را از اول روی تمام چهار fold آموزشی بیرونی fit می‌کنیم و فقط یک بار روی fold آزمون بیرونی پیشبینی می‌گیریم. این کار را برای همهٔ هایfold بیرونی تکرار کرده و در آخر پیشبینی‌ها را

با هم تجمیع میکنیم تا AUROC را به دست آوریم.
به این شکل، هر فرد با مدلی پیش‌بینی می‌شود که آن فرد نه در fit مدل و نه در انتخاب هاfeature و تنظیمات آن حضور نداشته است. پس AUROC به دست آمده واقعی تر است. در حالت نشت داده معمولا AUROC به شکل خوش‌بینانه بیشتر از عملکرد واقعی مدل گزارش می‌شود؛ مخصوصا وقتی انتخاب feature با استفاده از کل outcome انجام شده باشد.

۱۰. سوال ۱۰:

پاسخ:

چون مقدار AUROC هر دو مدل برابر با 0.83 است. پس از نظر قدرت تفکیک تفاوتی با هم ندارند؛ یعنی هر دو مدل تقریبا به یک اندازه می‌توانند افراد پرخطر را از افراد کم‌خطر تفکیک کنند. بنابراین فقط با نگاه کردن به AUROC نمیتوانییم بگوییم کدام مدل بهتر است.
اما اگر بخواهیم احتمال خطر را پیش‌بینی کنیم، مدل A انتخاب بهتری است. مقدار مورد نظر ما برای شیب کالیبراسیون 1 و برای عرض از مبدا 0 است. در مدل A این دو مقدار به ترتیب 0.98 و 0.02 هستند که خیلی به مقادیر ایده‌آل نزدیک‌اند. پس احتمال‌هایی که این مدل می‌دهد قابل اعتمادتر هستند.
اختلاف مقدار شبه R^2 برای دو مدل 0.02 است که تفاوت خاصی ایجاد نمیکند و دو مدل می‌توانند AUROC یکسانی داشته باشند ولی احتمال‌های خیلی متفاوتی تولید کنند.
برای اینکه کالیبراسیون مدل را بهتر بررسی کنیم، می‌توانیم نمودار کالیبراسیون رسم کنیم. در این نمودار احتمال پیش‌بینی‌شده را با فراوانی واقعی پیامد مقایسه می‌کنیم. اگر نقاط روی خط 45 درجه باشند، یعنی کالیبراسیون مدل خوب است. این نمودار علاوه بر شیب و عرض از مبدا، نشان می‌دهد که آیا در بعضی نواحی مدل خطر را بیش‌برآورد یا کم‌برآورد کرده است یا نه. با توجه به شیب 0.98 و عرض از مبدا 0.02، انتظار داریم منحنی کالیبراسیون مدل A به خط ایده‌آل نزدیک‌تر باشد؛ پس باز هم مدل A را ترجیح می‌دهیم.