به نام خدا

دانشکده ریاضی و آمار

علوم کامپیوتر
نیم‌سال دوم ۰۴-۰۵
داده کاوی

زهرا چراغی، محمد ملائی، داوود نصرتی

صورت سؤال

در یک مطالعه پزشکی، هدف پیش‌بینی ابتلا یا عدم ابتلا به یک بیماری مزمن با استفاده از مدل رگرسیون لجستیک است. در مقاله‌ی Smith و McKenna، چند شاخص مختلف Pseudo-R^2 برای ارزیابی برازش مدل‌های لجستیک مقایسه شده‌اند از جمله Cox–Snell، Nagelkerke، McFadden، McFadden Adjusted، Lave/Efron، Aldrich–Nelson و Veall–Zimmermann. این مقاله نشان می‌دهد که مقدار این شاخص‌ها می‌تواند بسته به نرخ پایه‌ی رخداد بیماری و هم‌خطی بین متغیرهای پیش‌بین تغییر کند، و شاخص Veall–Zimmermann نزدیک‌ترین مقدار را به R^2 در رگرسیون خطی معمولی نشان داده است.

اگر بین متغیرهای پیش‌بین، هم‌خطی بالا وجود داشته باشد، چه اثری بر شاخص‌های برازش مدل لجستیک انتظار می‌رود؟

در یک مسئله پزشکی با عدم‌توازن شدید کلاس‌ها، مثلاً شیوع بیماری 10%، کدام شاخص‌ها ممکن است تحت تأثیر نرخ پایه قرار گیرند و چرا؟

پاسخ

بر اساس مقاله‌ی Smith و McKenna، هم‌خطی زیاد میان متغیرهای پیش‌بین باعث کاهش مقدار شاخص‌های Pseudo-R^2 می‌شود. به بیان دیگر، وقتی متغیرهای پیش‌بین اطلاعات تکراری زیادی داشته باشند، مدل از نظر این شاخص‌ها برازش ضعیف‌تری نشان می‌دهد حتی اگر بعضی از ضرایب منفرد همچنان معنادار به نظر برسند.

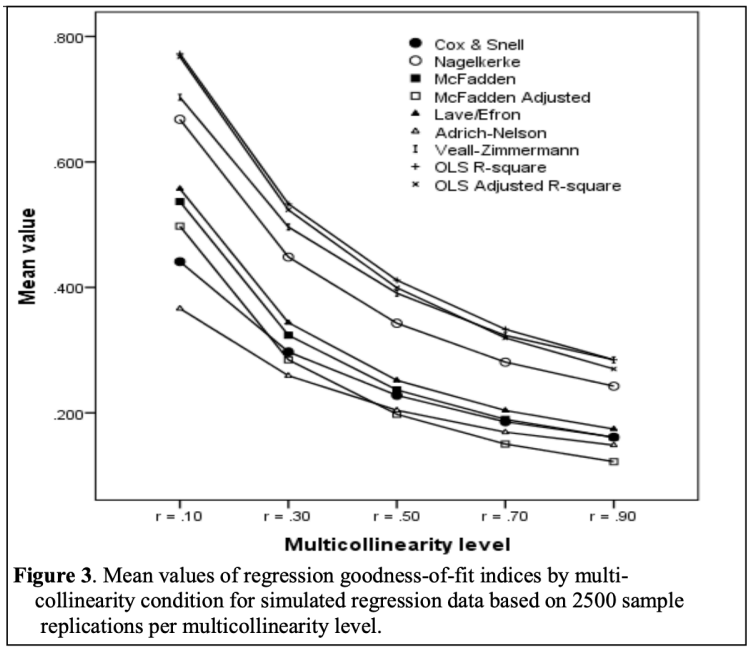


Figure 3. Mean values of regression goodness-of-fit indices by multi-collinearity condition for simulated regression data based on 2500 sample replications per multicollinearity level.

شکل ۱: کاهش میانگین شاخص‌های برازش با افزایش سطح هم‌خطی بین متغیرهای پیش‌بین

در جدول مقاله، با افزایش هم‌خطی از $r = .10$ به $r = .90$، مقدار همه‌ی شاخص‌ها کاهش پیدا کرده است. برای مثال، شاخص Veall–Zimmermann از حدود 0.70 به 0.28 و شاخص McFadden از حدود 0.54 به 0.16 رسیده است. نویسندگان نیز در بخش بحث مقاله اشاره می‌کنند که افزایش هم‌خطی باعث کاهش همه‌ی شاخص‌های Pseudo-R^2 شده است.

Table 4. Descriptive Statistics for Regression Goodness-of-Fit Indices by Multicollinearity

	Multicollinearity Level											
	Condition 1 (r = .10)		Condition 2 (r = .30)		Condition 3 (r = .50)		Condition 4 (r = .70)		Condition 5 (r = .90)		Total	
Index	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*
Maddala / Cox-Snell	.44	(.09)	.30	(.07)	.23	(.06)	.19	(.06)	.16	(.05)	.26	(.12)
Nagelkerke	.67	(.06)	.45	(.07)	.34	(.07)	.28	(.07)	.24	(.07)	.40	(.17)
McFadden	.54	(.07)	.32	(.06)	.24	(.06)	.19	(.06)	.16	(.05)	.29	(.15)
McFadden adjusted	.50	(.07)	.28	(.06)	.20	(.06)	.15	(.05)	.12	(.05)	.25	(.15)
Lave/Efron	.56	(.07)	.34	(.07)	.25	(.07)	.20	(.06)	.17	(.06)	.31	(.15)
Aldrich-Nelson	.37	(.06)	.26	(.06)	.20	(.05)	.17	(.05)	.15	(.04)	.23	(.09)
Veall-Zimmermann	.70	(.07)	.50	(.08)	.39	(.08)	.32	(.08)	.28	(.08)	.44	(.17)
OLS R^2*	.77	(.03)	.53	(.05)	.41	(.05)	.33	(.06)	.28	(.05)	.47	(.18)
OLS adjusted R^2*	.77	(.03)	.52	(.05)	.40	(.05)	.32	(.06)	.27	(.05)	.46	(.18)

Note. *Based on continuous outcome. Level. n = 2500 for each Condition.

شکل ۲: آمار توصیفی شاخص‌های برازش در سطوح مختلف هم‌خطی

در مسئله‌های پزشکی که با عدم‌توازن شدید کلاس‌ها روبه‌رو هستیم، مثلاً وقتی شیوع بیماری حدود 10% است، باید در تفسیر شاخص‌هایی که به نرخ پایه‌ی رخداد حساس‌اند دقت بیشتری داشت. طبق مقاله، اثر نرخ پایه روی همه‌ی شاخص‌ها یکسان نیست. بیشترین اثر روی شاخص‌های Cox–Snell / Maddala و Aldrich–Nelson دیده شده است یعنی شاخص‌هایی که نسخه‌ی اصلاح‌نشده محسوب می‌شوند.

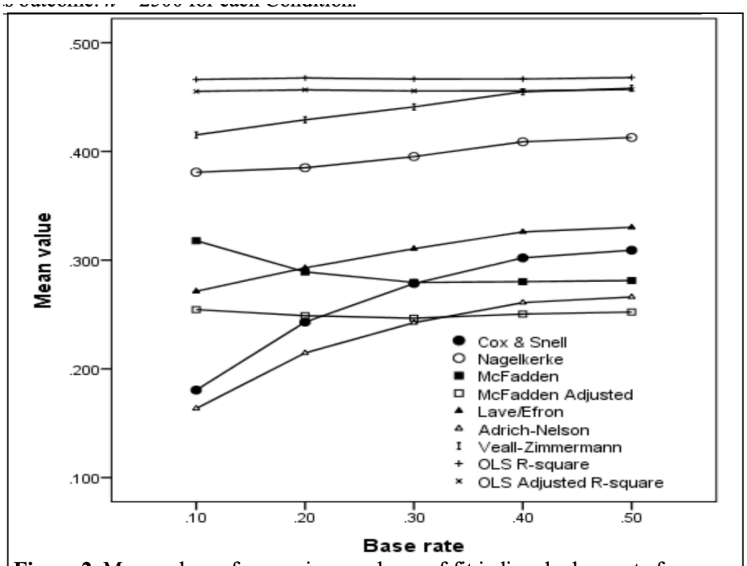


Figure 2. Mean values of regression goodness-of-fit indices by base rate for simulated regression data based on 2500 sample replications per base rate level.

شکل ۳: تغییر میانگین شاخص‌های برازش در نرخ‌های پایه‌ی مختلف رخداد بیماری

در نرخ پایه‌ی پایین، مقدار این شاخص‌ها معمولاً کمتر می‌شود. برای نمونه، در شیوع 10%، مقدار شاخص Cox–Snell حدود 0.18 و مقدار Aldrich–Nelson حدود 0.16 گزارش شده است در حالی که با نرخ پایه‌ی 50%، این مقادیر به حدود 0.31 و 0.27 می‌رسند.

Table 3. Descriptive Statistics for Regression Goodness-of-Fit Indices by Base Rate

	Base rate											
	$p = .10$		$p = .20$		$p = .30$		$p = .40$		$p = .50$		Total	
Index	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*	*M*	*(SD)*
Maddala / Cox-Snell	.18	(.08)	.24	(.10)	.28	(.12)	.30	(.12)	.31	(.13)	.26	(.12)
Nagelkerke	.38	(.17)	.38	(.16)	.40	(.17)	.41	(.16)	.41	(.17)	.40	(.17)
McFadden	.32	(.16)	.29	(.15)	.28	(.14)	.28	(.14)	.28	(.14)	.29	(.15)
McFadden adjusted	.25	(.16)	.25	(.15)	.25	(.14)	.25	(.14)	.25	(.14)	.25	(.15)
Lave/Efron	.27	(.17)	.29	(.15)	.31	(.15)	.33	(.15)	.33	(.15)	.31	(.15)
Aldrich-Nelson	.16	(.07)	.21	(.08)	.24	(.09)	.26	(.09)	.27	(.10)	.23	(.09)
Veall-Zimmermann	.42	(.18)	.43	(.17)	.44	(.17)	.45	(.16)	.46	(.17)	.44	(.17)
OLS R^2*	.47	(.18)	.47	(.18)	.47	(.18)	.47	(.18)	.47	(.18)	.47	(.18)
OLS adjusted R^2*	.46	(.18)	.46	(.18)	.46	(.18)	.46	(.18)	.46	(.18)	.46	(.18)

Note. *Based on continuous outcome. $n = 2500$ for each Condition.

شکل ۴: آمار توصیفی شاخص‌های برازش در نرخ‌های پایه‌ی مختلف

برای شاخص اصلاح‌نشده‌ی McFadden، مقاله نتیجه‌ی کمی متفاوتی گزارش کرده است. نویسندگان نشان می‌دهند که پایین‌ترین نرخ پایه، یعنی $p = .10$، حتی مقدار McFadden را افزایش داده است. بنابراین در داده‌های پزشکی با شیوع 10%، مقدار McFadden ممکن است نسبتاً بزرگ‌تر از حالتی با شیوع متعادل‌تر دیده شود. در نتیجه نباید این مقدار را مستقیماً به معنای قدرت پیش‌بینی بسیار بهتر مدل تفسیر کرد.

شاخص‌های اصلاح‌شده، مانند Nagelkerke و به‌ویژه Veall–Zimmermann، وابستگی کمتری به نرخ پایه‌ی خام دارند. زیرا برای محدودیت مقیاس و بیشینه‌ی مقدار ممکن اصلاح شده‌اند. مقاله نیز در چکیده نتیجه می‌گیرد که تغییر نرخ پایه اثر کمی بر نسخه‌های اصلاح‌شده داشته، اما نسخه‌های اصلاح‌نشده را بیشتر تحت تأثیر قرار داده است.

بنابراین، در یک مدل پزشکی با شیوع بیماری 10%، باید مقدار خام شاخص‌های Cox–Snell، Aldrich–Nelson و تا حدی McFadden را با احتیاط تفسیر کرد. بخشی از تغییر مقدار این شاخص‌ها ممکن است ناشی از نادر بودن بیماری باشد، نه الزاماً کیفیت واقعی مدل. برای مقایسه‌ای نزدیک‌تر با R^2 در رگرسیون خطی، مقاله شاخص Veall–Zimmermann را مناسب‌تر معرفی می‌کند هرچند این شاخص هم نباید کاملاً مانند R^2 در رگرسیون خطی تفسیر شود.